

# Introducción a la estimación espectral

## Episodio III: técnicas paramétricas para espectros de línea

Andrés Altieri

Procesamiento de Señales II  
Facultad de Ingeniería, Universidad de Buenos Aires

Segundo cuatrimestre de 2015

- 1 El modelo de sinusoides
- 2 Técnica MUSIC o de Pisarenko
- 3 Apéndice: El problema de estimación de direcciones de arribo

## 1 El modelo de sinusoides

# El modelo de sinusoides en ruido

- En muchas aplicaciones vinculadas a comunicaciones, radar, etc. se trabaja con un modelo de sinusoides complejas inmersas en ruido:

$$y[m] = \sum_{k=1}^K \alpha_k e^{j\omega_k m + \phi_k} + v[m].$$

donde:

- Las  $\{\omega_k\}_k$  son las frecuencias de las sinusoides
- Las  $\{\phi_k\}_k$  son sus fases.
- Las  $\{\alpha_k\}_k$  son sus amplitudes, desconocidas pero fijas.
- $\{v[m]\}_m$  es ruido blanco complejo, circular, de media nula y varianza  $\sigma_v^2$ .
- Asumimos que el número  $K$  de sinusoides es conocido, si no hay que estimarlo.

## Objetivo

Estimar las frecuencias  $\omega_k$  de cada senoide. Típicamente hay pocas muestras y la frecuencias podrían ser muy cercanas. Luego de las  $\omega_k$  pueden estimarse amplitud y fase.

# Por qué sinusoides complejas

- Las sinusoides son complejas, porque estan asociadas a un proceso de modulación/demodulación.
- La señal que es recibida en tiempo continuo es:

$$\alpha_k(\cos(\omega_k t + \phi_k) \cos(\omega_c t) + \sin(\omega_k t + \phi_k) \sin(\omega_c t))$$

donde  $\omega_c$  es la frecuencia de portadora,  $\omega_c \gg \omega_k$ .

- Luego es demodulada a banda base, filtrada con un pasabajos, muestreada y tratada como una señal compleja, dando:

$$\alpha_k(\cos(\omega_k m + \phi_k) + j \sin(\omega_k m + \phi_k)) = \alpha_k e^{j\omega_k m + \phi_k}.$$

La tasa de muestreo  $f_s$  debe cumplir el teorema del muestreo, es decir:

$$f_s > 2 \max\{f_1, \dots, f_K\}.$$

# Modelo para el ruido

- El modelo asume ruido blanco.
- Si éste no lo es, las técnicas que presentaremos pueden perder desempeño.
- Para mitigar esto, podría hacerse lo siguiente:
  - ▶ Si el tiempo de decorrelación del ruido en tiempo continuo (previo al muestreo) es conocido, digamos,  $T_c$ , podría elegirse el período de muestreo  $T_s > T_c$  para que el ruido muestreado sea blanco.

En ese caso la frecuencia de muestreo  $f_s$  debería cumplir:

$$2 \max\{f_1, \dots, f_K\} < f_s < \frac{1}{T_c}.$$

- ▶ Si la estadística del ruido es conocida, podría implementarse un filtro blanqueador. Las sinusoides no se verían afectas más que en su amplitud.
- ▶ Si no es conocido, podría utilizarse la técnica LS no lineal para estimar las frecuencias.

# El modelo de las fases $\phi_k$

- Si se asume que las fases son constantes desconocidas, el modelo obtenido no es ESA.
- La aleatoriedad viene unicamente del ruido. Por ejemplo, la media no es constante:

$$\mathbb{E}[y[m]] = \sum_{k=1}^K \alpha_k e^{j\omega_k m + \phi_k} + \mathbb{E}[v[m]] = \sum_{k=1}^K \alpha_k e^{j\omega_k m + \phi_k} \neq \text{cte.}$$

- Por lo tanto, normalmente se considera lo siguiente:

## Modelo para la fase

Las fases  $\{\phi_k\}_k$  son variables aleatorias independientes (entre sí y del ruido) y uniformes  $[-\pi, \pi]$ .

Antes de comenzar la transmisión, cada fase se elije en forma uniforme  $[-\pi, \pi]$  e independiente de todo, y luego se mantiene constante.

# Recapitulación del problema

- Contamos con  $N$  muestras de una señal discreta

$$y[m] = \sum_{k=1}^K \alpha_k e^{j(\omega_k m + \phi_k)} + v[m],$$

que es la suma de  $K$  (conocido) sinusoides complejas.

- Queremos estimar las frecuencias  $\omega_k$  de cada senoide.
- Asumimos que las amplitudes  $\alpha_k$  son fijas pero desconocidas.
- Luego de estimar  $\omega_k$  podemos estimar las amplitudes  $\alpha_k e^{j\phi_k}$ .
- Las fases  $\phi_k$  son IID uniformes en  $[-\pi; \pi]$ .
- El ruido es gaussiano blanco, circular, de varianza  $\sigma_v^2$ , independiente de las fases.



# Momentos de la señal y: media

- Buscamos la media de la señal y:

$$\begin{aligned}\mathbb{E}[y[m]] &= \mathbb{E}\left[\sum_{k=1}^K \alpha_k e^{j(\omega_k m + \phi_k)} + v[m]\right] \\ &= \sum_{k=1}^K \alpha_k e^{j\omega_k m} \mathbb{E}[e^{j\phi_k}] + \mathbb{E}[v[m]] \\ &= 0\end{aligned}$$

donde usamos que:

$$\mathbb{E}[e^{j\phi_k}] = \int_{-\pi}^{\pi} \frac{1}{2\pi} e^{j\phi_k} d\phi_k = 0$$

## Conclusión

$$\mathbb{E}[y[m]] = 0 \quad \forall m$$

# Momentos de la señal y: autocovarianza

- La autocovarianza:

$$\begin{aligned} r[m, m-n] &= \mathbb{E} [y[m]y^*[m-n]] \\ &= \mathbb{E} \left[ \left\{ \sum_{k=1}^K \alpha_k e^{j(\omega_k m + \phi_k)} + v[m] \right\} \right. \\ &\quad \times \left. \left\{ \sum_{p=1}^K \alpha_p e^{-j[\omega_p(m-n) + \phi_p]} + v[m-n]^* \right\} \right] \\ &= \sum_{k=1}^K \sum_{p=1}^K \alpha_k \alpha_p e^{j[\omega_k m - \omega_p(m-n)]} \mathbb{E} [e^{j[\phi_k - \phi_p]}] + \mathbb{E} [v[m]v[m-n]^*] \\ &= \sum_{k=1}^K \alpha_k^2 e^{j\omega_k n} + \sigma_v^2 \delta_{n,0} \equiv r_y[n]. \end{aligned}$$

- Usamos que el ruido es blanco de media nula, independiente de las fases.
- Además, usamos que las fases son independientes:

$$\mathbb{E} [e^{j[\omega_k m - \omega_p(m-n)]}] = \mathbb{1}\{k=p\}.$$

# Momentos de la señal y: por qué espectro de líneas

## Características de la señal y

- La señal y es ESA, de media nula y autocovarianza:

$$r_y[n] = \sum_{k=1}^K \alpha_k^2 e^{j\omega_k n} + \sigma_v^2 \delta_{n,0}.$$

- La PSD de la señal y es:

$$\phi_y(\omega) = \text{DTFT}(r_y)(\omega) = 2\pi \sum_{k=1}^K \alpha_k^2 \delta(\omega - \omega_p) + \sigma^2.$$

De ahí el nombre de espectro de líneas.

# Técnicas de alta resolución

- Las técnicas que describiremos son algunas de las llamadas de *técnicas de alta resolución* (o super).
- Se llaman así porque, en teoría, permiten separar dos frecuencias  $f_1, f_2$  tales que:

$$|f_1 - f_2| < 1/N$$

que es el límite de resolución del periodograma.

- Proveen estimadores consistentes de las frecuencias.
- Nos enfocaremos en los estimadores que se basan en el modelo de la matriz de covarianza de la señal.
- Existen otros basados en modelado ARMA o técnicas de LS no lineal.

# Representación matricial de la señal y (I)

- Supongamos que tenemos contamos con muestras de una senoide  $x$  de amplitud  $\alpha$ :

$$x[m] = \alpha e^{j(\omega m + \phi)}.$$

- En el instante  $[m - n]$  dicha senoide vale:

$$x[m - n] = \alpha e^{j(\omega(m-n) + \phi)} = \alpha e^{j(\omega m + \phi)} e^{-j\omega n} = x[m] e^{-j\omega n}.$$

- Armamos un vector con  $L \leq N$  muestras:

$$\mathbf{x}[m] = \begin{bmatrix} x[m] \\ x[m-1] \\ \vdots \\ x[m-L+1] \end{bmatrix} = \begin{bmatrix} 1 \\ e^{-j\omega} \\ \vdots \\ e^{-j\omega(L-1)} \end{bmatrix} x[m]$$

## Representación matricial (II)

- Si llamamos:

$$\mathbf{a}(\omega) = \begin{bmatrix} 1 & e^{-j\omega} & \dots & e^{-j\omega(L-1)} \end{bmatrix}^T$$

entonces para una senoide podemos escribir:

$$\mathbf{x}[n] = \mathbf{a}[\omega] \alpha e^{j(\omega n + \phi)}$$

- Ahora supongamos que tenemos las  $K$  senoideas y las  $L$  muestras:

$$\mathbf{y}[L] = \begin{bmatrix} y[L] \\ y[L-1] \\ \vdots \\ y[1] \end{bmatrix} = \begin{bmatrix} \mathbf{a}(\omega_1) & \dots & \mathbf{a}(\omega_K) \end{bmatrix} \begin{bmatrix} \alpha_1 e^{j(\omega_1 L + \phi_1)} \\ \vdots \\ \alpha_K e^{j(\omega_K L + \phi_K)} \end{bmatrix} + \begin{bmatrix} v[L] \\ v[L-1] \\ \vdots \\ v[1] \end{bmatrix}$$

o en forma más compacta (omitiendo los índices de tiempo):

$$\mathbf{y} = \mathbf{A}\mathbf{e} + \mathbf{v}.$$

# Matriz de covarianza de las muestras (I)

- El vector de muestras tiene media nula.
- Su covarianza vale:

$$\mathbb{E} [\mathbf{y}\mathbf{y}^H] = \mathbb{E} [(\mathbf{A}\mathbf{e})(\mathbf{A}\mathbf{e})^H] + \sigma_v^2 \mathbf{I} = \mathbf{A} \mathbb{E} [\mathbf{e}\mathbf{e}^H] \mathbf{A}^H + \sigma_v^2 \mathbf{I}.$$

- Al hacer  $\mathbf{e}\mathbf{e}^H$  obtenemos una matriz de  $K \times K$  que tiene todos los productos de los elementos de  $\mathbf{e}$  tomados de a dos. Por ejemplo, si  $K = 2$  tenemos:

$$\begin{aligned} \mathbf{e}\mathbf{e}^H &= \begin{bmatrix} \alpha_1 e^{j(\omega_1 n + \phi_1)} \\ \alpha_2 e^{j(\omega_2 n + \phi_2)} \end{bmatrix} \begin{bmatrix} \alpha_1 e^{-j(\omega_1 n + \phi_1)} & \alpha_2 e^{-j(\omega_2 n + \phi_2)} \end{bmatrix} \\ &= \begin{bmatrix} \alpha_1^2 & \alpha_1 \alpha_2 e^{((\omega_1 - \omega_2)n + (\phi_1 - \phi_2))i} \\ \alpha_1 \alpha_2 e^{((\omega_2 - \omega_1)n + (\phi_2 - \phi_1))i} & \alpha_2^2 \end{bmatrix}. \end{aligned}$$

## Matriz de covarianza de las muestras (II)

- Al tomar esperanza, tenemos que:

$$E[\mathbf{e}\mathbf{e}^H] = \begin{bmatrix} \alpha_1^2 & 0 & \dots & 0 \\ 0 & \alpha_2^2 & \ddots & \vdots \\ \vdots & \ddots & \ddots & 0 \\ 0 & \dots & 0 & \alpha_K \end{bmatrix} \triangleq \mathbf{D}$$

según vimos al calcular la covarianza.

### Observaciones

Podemos escribir:

$$\mathbf{R} \triangleq \mathbb{E}[\mathbf{y}\mathbf{y}^H] = \mathbf{A}\mathbf{D}\mathbf{A}^H + \sigma_v^2\mathbf{I}$$

donde vemos que:

- La matriz  $\mathbf{D}$  es constante y contiene las amplitudes de las sinusoides al cuadrado.
- En la matriz  $\mathbf{A} \equiv \mathbf{A}(\omega)$  depende de las  $\omega_k$  a estimar y depende de  $L$ .



# Propiedades de $\mathbf{A}$ (un poco de álgebra)

- $\mathbf{A}$  es de  $L \times K$  con  $L \geq K$  (más muestras que sinusoides).
- Supongamos que  $K = L$  y busquemos el núcleo de  $\mathbf{A}^T$ . Sea

$$\mathbf{z} = \begin{bmatrix} z_0 & \dots & z_{L-1} \end{bmatrix}^T.$$

Hacemos:

$$\mathbf{A}^T \mathbf{z} = \begin{bmatrix} \mathbf{a}^T(\omega_1) \mathbf{z} \\ \mathbf{a}^T(\omega_2) \mathbf{z} \\ \vdots \\ \mathbf{a}^T(\omega_K) \mathbf{z} \end{bmatrix} = \begin{bmatrix} z_0 + z_1 e^{-j\omega_1} + z_2 (e^{-j\omega_1})^2 + \dots + z_{L-1} (e^{-j\omega_1})^{(L-1)} \\ z_0 + z_1 e^{-j\omega_2} + z_2 (e^{-j\omega_2})^2 + \dots + z_{L-1} (e^{-j\omega_2})^{(L-1)} \\ \vdots \\ z_0 + z_1 e^{-j\omega_K} + z_2 (e^{-j\omega_K})^2 + \dots + z_{L-1} (e^{-j\omega_K})^{(L-1)} \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ \vdots \\ 0 \end{bmatrix}$$

- Son polinomios en  $e^{j\omega_k}$ .
- Sería buscar  $K = L$  raíces distintas en un polinomio de orden  $L - 1$ . ¡No existen!

## Conclusión

- Por lo anterior, si  $K = L$  entonces  $\mathbf{A}$  es inversible, lo que implica que sus columnas son L.I. y  $\text{rg}(\mathbf{A}) = K$ .
- Si agregamos más filas, es decir,  $L > K$ , las columnas de  $\mathbf{A}$  siguen siendo L.I.
- Por lo tanto  $\text{rg}(\mathbf{A}) = K$  siempre que  $L \geq K$ .

# Trabajando con $\mathbf{ADA}^H$

- $\mathbf{D}$  es inversible y  $\text{rg}(\mathbf{A}) = K$ . Esto implica que
  - ▶  $\text{rg}(\mathbf{AD}) = K$ .
  - ▶  $\text{rg}(\mathbf{ADA}^H) = K$ .
  - ▶  $\mathbf{ADA}^H$  es hermitica y diagonalizable.
  - ▶  $\mathbf{ADA}^H$  es de  $L \times L$  y tiene rango  $K$  o sea que tiene  $L - K$  autovalores nulos y el resto positivos
- Entonces  $\mathbf{R} = \mathbf{ADA}^H + \sigma_v^2 \mathbf{I}$  tiene las siguientes propiedades:
  - ▶ Es hermítica y es diagonalizable.
  - ▶ Tiene  $L - K$  autovalores que valen  $\sigma_v^2$  y  $K$  autovalores mayores que  $\sigma_v^2$ , es decir:

$$\mathbf{R} = \mathbf{P}\tilde{\mathbf{D}}\mathbf{P}^H$$
$$\tilde{\mathbf{D}} = \begin{bmatrix} \lambda_1 + \sigma_v^2 & 0 & \dots & \dots & \dots & 0 \\ 0 & \ddots & \ddots & \ddots & & \vdots \\ 0 & \ddots & \lambda_K + \sigma_v^2 & \ddots & & \vdots \\ 0 & \ddots & & \sigma_v^2 & & \vdots \\ 0 & \ddots & \ddots & & \ddots & \vdots \\ 0 & \dots & \dots & & & \sigma_v^2 \end{bmatrix}$$

## 2 Técnica MUSIC o de Pisarenko

# Técnica MUSIC o de Pisarenko

- MUSIC significa *MUltiple SIgnal Classification*.
- Esta técnica se apoya en las propiedades de la matriz  $\mathbf{R}$  expuestas hasta ahora para estimar las frecuencias deseadas.
- La técnica de Pisarenko [1973] es MUSIC[1979] con  $L = K + 1$ .
- Es una de las técnicas más simples de entender.

# Principio del método MUSIC (I)

- $\mathbf{R}$  tiene  $L - K$  autovalores de valor  $\sigma_v^2$  y  $L - K$  autovectores L.I. asociados al  $\sigma_v^2$ .
- Sea  $\mathbf{G}$  que una matriz con los autovectores asociados a  $\sigma_v^2$ :

$$\mathbf{G} = [\mathbf{g}_1, \dots, \mathbf{g}_{L-K}]$$

- Entonces tenemos:

$$\mathbf{R}\mathbf{G} = (\mathbf{A}\mathbf{D}\mathbf{A}^H + \sigma_v^2\mathbf{I})\mathbf{G} = \sigma_v^2\mathbf{G}$$

y por lo tanto:

$$\mathbf{A}\mathbf{D}\mathbf{A}^H\mathbf{G} = \mathbf{0}$$

# Principio del método MUSIC (II)

- Como  $\mathbf{AD}$  es de  $L \times K$  y  $\text{rg}(\mathbf{AD}) = K$  entonces las columnas de  $\mathbf{AD}$  son L.I.
- Podemos multiplicar por  $(\mathbf{AD})^H$  a izquierda para obtener:

$$(\mathbf{AD})^H(\mathbf{AD})\mathbf{A}^H\mathbf{G} = \mathbf{0}$$

- Como  $\text{rg}((\mathbf{AD})^H(\mathbf{AD})) = \text{rg}(\mathbf{AD}) = K$  y  $(\mathbf{AD})^H(\mathbf{AD})$  es de  $K \times K$  tenemos que  $(\mathbf{AD})^H(\mathbf{AD})$  es inversible.

## Conclusión

- Finalmente, tenemos que:

$$\mathbf{ADA}^H\mathbf{G} = \mathbf{0} \Leftrightarrow \mathbf{A}^H\mathbf{G} = \mathbf{0}.$$

Esto implica que las columnas de  $\mathbf{A}$  son ortogonales a las de  $\mathbf{G}^H$ , es decir,  $\text{Col}(\mathbf{A}) \subset \text{Nul}(\mathbf{G}^H)$ .

- Pero como  $\text{rg}(\mathbf{A}) = K$  y  $\text{rg}(\mathbf{G}) = L - K$  entonces  $\dim(\text{Nul}(\mathbf{G})) = K$  y entonces:

$$\text{Col}(\mathbf{A}) = \text{Nul}(\mathbf{G}^H).$$

# Solución

- Sabemos que la columna  $j$ -ésima de  $\mathbf{A}$  es de la forma:

$$\mathbf{a}(\omega_j) = \begin{bmatrix} 1 & e^{-i\omega_j} & \dots & e^{-i\omega_j(L-1)} \end{bmatrix}^T$$

donde nuestro objetivo es averiguar  $\omega_j$ .

## Observaciones

- Como  $\mathbf{G}^H \mathbf{A} = \mathbf{0}$ , sabemos que

$$\mathbf{G}^H \mathbf{a}(\omega_j) = \mathbf{0} \quad j = 1, \dots, K.$$

es decir, las  $\omega_j$  que queremos estimar son soluciones de la ecuación:

$$\mathbf{G}^H \mathbf{a}(\omega) = \mathbf{0}.$$

- ¿ Hay otras soluciones que no sean las que buscamos ?

**No**, porque los vectores  $\mathbf{a}(\omega_j)$  son L.I. si las  $\omega_j$  son diferentes y  $\dim(\text{Nul}(\mathbf{G}^H)) = K$ , por lo que no hay un conjunto de más de  $K$  vectores L.I..

Además las columnas de  $\mathbf{A}$  son L.I. y por lo tanto generan **todo el núcleo de  $\mathbf{G}^H$** . Por ende, **no puede haber más que las  $K$  soluciones halladas**, que son las frecuencias que deseamos estimar.

# Método teórico de resolución para MUSIC

## Algoritmo MUSIC teórico

- 1 Calculamos  $\mathbf{A}\mathbf{D}\mathbf{A}^H + \sigma_v^2\mathbf{I}$  y la diagonalizamos.
  - 2 Armamos  $\mathbf{G}$  la matriz con los autovectores asociados a  $\lambda = 0$ .
  - 3 Obtenemos las  $\omega_j$  resolviendo la ecuación  $\mathbf{G}^H\mathbf{a}(\omega_j) = \mathbf{0}$  que tiene  $K$  soluciones.
- Observar que se requiere como mínimo que  $L \geq K + 1$ , de otro modo  $\mathbf{G}$  no puede armarse (al menos una muestra más que el número de sinusoides).
  - Dado que no conocemos exactamente la matriz  $\mathbf{G}$  deben recurrirse a otra estrategia para obtener soluciones aproximadas.
  - Esto da lugar a dos versiones del algoritmo MUSIC.



# Consideraciones prácticas

- En la práctica debemos **estimar**  $\mathbf{G}$  de modo que resolviendo:

$$\hat{\mathbf{G}}^H \mathbf{a}(\omega) = \mathbf{0}$$

puede **no dar**  $K$  soluciones.

- Se busca una solución en un dominio ampliado reemplazando:

$$\mathbf{a}(\omega) = \begin{bmatrix} 1 & e^{-j\omega} & \dots & e^{-j\omega(L-1)} \end{bmatrix}^T$$

por:

$$\mathbf{p}(z) = \begin{bmatrix} 1 & z & z^2 & \dots & z^{L-1} \end{bmatrix}^T$$

- Se tiene que:

$$\mathbf{p}(z)|_{z=e^{j\omega}} = \mathbf{a}(\omega)$$

Puede resolverse:

$$\hat{\mathbf{G}}^H \mathbf{p}(z) = 0$$

La solución de esta ecuación dará  $L - 1$  soluciones, de las cuales  $K$  deberían estar cerca del círculo unitario y ser cercanas a las verdaderas si  $\hat{\mathbf{G}}$  es un buen estimador.

## Ejemplo (I)

- Consideremos una sola senoide ( $K = 1$ ) y tomamos  $L = 2$ .
- En ese caso  $\mathbf{G}$  es de  $2 \times 1$ .
- Supongamos que la  $\mathbf{G}$  verdadera es de la forma:

$$\mathbf{G}^H = \begin{bmatrix} -e^{-i} & 1 \end{bmatrix}.$$

- Resolvemos:

$$\mathbf{G}^H \mathbf{a}(\omega) = \begin{bmatrix} -e^{-i} & 1 \end{bmatrix} \begin{bmatrix} 1 \\ e^{-i\omega} \end{bmatrix} = e^{-i\omega} - e^{-i} = 0$$

para obtener la frecuencia buscada:

$$\omega = 1$$

## Ejemplo (II)

- Supongamos al estimar  $\mathbf{G}$  hubo algunos errores numéricos y obtuvimos:

$$\hat{\mathbf{G}}^H = \begin{bmatrix} -e^{-i} & 0,99 \end{bmatrix}.$$

- Al intentar resolver  $\hat{\mathbf{G}}^H \mathbf{a}(\omega) = 0$  encontramos un problema porque no tiene solución para  $\omega$  real.
- Sin embargo al resolver la ecuación  $\hat{\mathbf{G}}^H \mathbf{p}(z) = \mathbf{0}$ :

$$\hat{\mathbf{G}}^H \mathbf{p}(z) = \begin{bmatrix} -e^{-i} & 0,99 \end{bmatrix} \begin{bmatrix} 1 \\ z \end{bmatrix} = 0$$



obtenemos:

$$z = 1,01e^{-i}.$$

- La solución obtenida no está en el círculo unitario pero la fase de  $z$  nos da la frecuencia buscada, es decir, deducimos que:

$$\omega \approx 1$$

## Ejemplo (III)



- ○ Cero verdadero:  $\omega = e^{-i}$ .
- □ Cero obtenido:  $\omega = 1,01e^{-i}$ .
- $\omega = 1$  [rad].

# Cómo reducir la complejidad computacional

- Además sabemos que:

$$\text{Nul}(\mathbf{G}^H) = \text{Nul}(\mathbf{G}\mathbf{G}^H),$$

de modo que los que se verifica:

$$\mathbf{G}^H \mathbf{p}(z) = \mathbf{0} \Leftrightarrow \mathbf{p}(z)^H \mathbf{G}\mathbf{G}^H \mathbf{p}(z) = 0$$

- Resolviendo entonces la ecuación:

$$\mathbf{p}(z^{-1})^T \mathbf{G}^H \mathbf{G} \mathbf{p}(z) = 0$$

obtenemos el mismo resultado que resolviendo el problema original.

- Es buscar los ceros de un polinomio real de orden  $2(L - 1)$
- Esto da lugar a MUSIC en su versión de las raíces.

## Solución propuesta

- 1 Estimar de  $\mathbf{R}$  de  $L \times L$  a partir de las  $N$  muestras de  $y$ .
- 2 Diagonalizar el estimado de  $\mathbf{R}$  y obtener un estimado de  $\mathbf{G}$ .
- 3 Armar el vector

$$\mathbf{p}(z) = \begin{bmatrix} 1 & z & z^2 & \dots & z^{L-1} \end{bmatrix}$$

- 4 Se obtiene el polinomio de orden  $2(L - 1)$ :

$$\mathbf{p}(z^{-1})^T \mathbf{G}^H \mathbf{G} \mathbf{p}(z),$$

que tiene  $2(L - 1)$  raíces, en pares recíprocos conjugados.

- 5 Buscar las  $L - 1$  raíces que están en el círculo  $|z| \leq 1$ .
- 6 De las  $L - 1$  raíces obtenidas seleccionar las  $K$  raíces más cercanas al círculo unidad  $\{c_i\}_{k=1}^K$  y estimar

$$\hat{\omega}_k = \text{fase}\{c_k\} \quad k = 1, \dots, K.$$

# Otra alternativa a la solución del problema

- Hemos visto que nuestro problema puede reformularse a resolver:

$$\mathbf{p}(z^{-1})^T \hat{\mathbf{G}} \hat{\mathbf{G}}^H \mathbf{p}(z) = 0 \quad (1)$$

con  $z$  complejo.

## Observación

- Sabemos que las  $K$  soluciones buscadas estarán muy cerca del círculo unitario, pero no exactamente sobre él.
- Esto implica que si evaluamos  $\mathbf{a}(\omega)^H \mathbf{G}^H \mathbf{G} \mathbf{a}(\omega)$  cerca de una solución de (1) tendremos:

$$\mathbf{a}(\omega)^H \hat{\mathbf{G}} \hat{\mathbf{G}}^H \mathbf{a}(\omega) \approx 0.$$

- Esto nos da otra forma de resolver el problema.

## Algoritmo espectral

- Estimar de  $\mathbf{R}$  de  $L \times L$  a partir de las  $N$  muestras de  $y(n)$ .
- Diagonalizar  $\hat{\mathbf{R}}$  y obtener  $\hat{\mathbf{G}}$ .
- Obtener las frecuencias deseadas buscando los  $\omega$  en  $[-\pi; \pi]$  donde la función:

$$\frac{1}{\mathbf{a}(\omega)^H \hat{\mathbf{G}} \hat{\mathbf{G}}^H \mathbf{a}(\omega)}$$

tiene sus  $K$  máximos (donde  $\mathbf{a}(\omega)^H \hat{\mathbf{G}} \hat{\mathbf{G}}^H \mathbf{a}(\omega)$  es casi nula).



# Approach *forwards-backwards* para estimar $\mathbf{R}$ (I)

- Podríamos usar el estimador de  $\mathbf{R}$ :

$$\hat{\mathbf{R}} \approx \frac{1}{N} \sum_{n=L}^N \mathbf{y}[n] \mathbf{y}[n]^H.$$

que es el que usamos en la Parte 2 para el estimador LS de procesos autoregresivos. Es el estimador de la covarianza de un predictor lineal de un paso hacia adelante (en *forwards*).

- Se observó empíricamente que para estimar la frecuencia es mejor utilizar el estimador modificado:

$$\hat{\mathbf{R}}_{\text{FB}} = \frac{1}{2}(\hat{\mathbf{R}} + \mathbf{J} \hat{\mathbf{R}}^T \mathbf{J}).$$

donde:

$$\mathbf{J} = \begin{bmatrix} 0 & & 1 \\ & \ddots & \\ 1 & & 0 \end{bmatrix}$$

- $\mathbf{J} \hat{\mathbf{R}}^T \mathbf{J}$  es la matriz de covarianza asociada a un predictor en *backwards*, es decir, a un predictor que predice la muestra  $i$  en función de las  $L$  muestras posteriores.

# Algunos ejemplos (I)

- En las siguientes simulaciones consideraremos frecuencias normalizadas, es decir, sabiendo que:

$$-\pi \leq \omega \leq \pi$$

definiremos una frecuencia normalizada:

$$\bar{\omega} = \frac{\omega}{\pi}.$$

De esta forma trabajamos con frecuencias en el intervalo  $[-1; 1]$ .

- Al hablar de la “resolución” de una técnica, en este contexto nos referimos a la capacidad de detectar y distinguir dos frecuencias próximas.
- Diremos que dos frecuencias son “próximas” si:

$$|\bar{\omega}_1 - \bar{\omega}_2| < \frac{1}{N}.$$

## Algunos ejemplos (II)



- Supongamos que disponemos de  $K = 3$  sinusoides complejas de frecuencias normalizadas:

$$\bar{\omega}_1 = \frac{1}{4} \quad \bar{\omega}_2 = \frac{1}{4} + \frac{0,5}{N} \quad \hat{\omega}_3 = \frac{1}{4} + \frac{1}{N}$$

donde  $N$  es el número de muestras.

- Dichas sinusoides pueden considerarse próximas.
- Consideraremos distintos valores para las amplitudes  $\alpha_k$  y distintos valores de  $K$  y  $L$  para analizar la performance del método.
- Consideramos  $N = 20$  siempre.
- No colocamos ruido en estas pruebas.

# Algoritmo de Pisarenko ( $K = 3, L = K + 1, N = 20$ )



Frecuencias reales:

$$\bar{\omega}_1 = 0,250$$

$$\bar{\omega}_2 = 0,275$$

$$\bar{\omega}_3 = 0,300$$

$$\alpha_i = 1 \quad i = 1, 2, 3$$

Estimación por método espectral:

$$\bar{\omega}_1 = 0,250$$

$$\bar{\omega}_2 = 0,275$$

$$\bar{\omega}_3 = 0,300$$

Estimación por método de frecuencia:

$$\bar{\omega}_1 = 0,250$$

$$\bar{\omega}_2 = 0,275$$

$$\bar{\omega}_3 = 0,300$$

# Algunos ejemplos: sinusoides más cercanas y distinta amplitud

- Supongamos que disponemos de  $K = 3$  sinusoides complejas de frecuencias normalizadas:



$$\bar{\omega}_1 = \frac{1}{4} \quad \bar{\omega}_2 = \frac{1}{4} + \frac{0,1}{N} \quad \hat{\omega}_3 = \frac{1}{4} + \frac{0,2}{N}$$

donde  $N$  es el número de muestras.

- Dichas sinusoides pueden considerarse muy próximas.
- Consideremos:

$$\alpha_1 = 0,1 \quad \alpha_2 = 0,3 \quad \alpha_3 = 0,5$$

# Algoritmo de Pisarenko ( $K = 3, L = 4, N = 20$ )



Frecuencias reales:

$$\bar{\omega}_1 = 0,250$$

$$\bar{\omega}_2 = 0,255$$

$$\bar{\omega}_3 = 0,260$$

$$\alpha_1 = 1 \quad \alpha_2 = 0,3 \quad \alpha_3 = 0,5$$

Estimación por método espectral:

$$\bar{\omega}_1 = 0,2497$$

$$\bar{\omega}_3 = 0,2603$$



Estimación por método de frecuencia:

$$\bar{\omega}_1 = 0,2497$$

$$\bar{\omega}_2 = 0,2597$$

$$\bar{\omega}_3 = 0,2603$$

# Algoritmo MUSIC para ( $K = 3, L = 10, N = 20$ )



Frecuencias reales:

$$\bar{\omega}_1 = 0,250$$

$$\bar{\omega}_2 = 0,255$$

$$\bar{\omega}_3 = 0,260$$

$$\alpha_1 = 1 \quad \alpha_2 = 0,3 \quad \alpha_3 = 0,5$$

Estimación por método espectral:

$$\bar{\omega}_1 = 0,250$$

$$\bar{\omega}_3 = 0,254$$

$$\bar{\omega}_3 = 0,261$$



Estimación por método de frecuencia:

$$\bar{\omega}_1 = 0,250$$

$$\bar{\omega}_2 = 0,260$$

$$\bar{\omega}_3 = 0,255$$

# Algoritmo MUSIC para ( $K = 3, L = 10, N = 20$ )



Frecuencias reales:

$$\bar{\omega}_1 = 0,250$$

$$\bar{\omega}_2 = 0,255$$

$$\bar{\omega}_3 = 0,260$$

$$\alpha_1 = 1 \quad \alpha_2 = 0,3 \quad \alpha_3 = 0,5$$

Estimación por método espectral:

$$\bar{\omega}_1 = 0,250$$

$$\bar{\omega}_3 = 0,254$$

$$\bar{\omega}_3 = 0,261$$

Estimación por método de frecuencia:

$$\bar{\omega}_1 = 0,250$$

$$\bar{\omega}_2 = 0,260$$

- Aumentar  $L$  mejora la capacidad de discriminar en frecuencia.
- Observar los  $(L - K - 1)$  ceros adicionales




- Existen formas de reducir la complejidad computacional de MUSIC e incluso técnicas modificadas para que no haya ceros de ruido.
- Existen otras técnicas similares con algunas ventajas y desventajas:
  - ▶ Técnica de Tufts-Kumaresan o *min-norm* [1983]:
    - ★ Utiliza que  $Col(\mathbf{G})$  es (asintoticamente) ortogonal a  $Col(\mathbf{A})$ . Se busca un  $\mathbf{g} \in Col(\mathbf{G})$  y se buscan los ceros del polinomio:
$$\mathbf{g}^T a(\omega).$$

El  $\mathbf{g}$  se elije de modo que la primera componente sea 1 y su norma también.
    - ★ Tiene una precisión similar a MUSIC con un costo computacional menor, pues el  $\mathbf{g}$  se halla sin buscar autovectores y autovalores.
  - menor.
  - ▶ Técnica ESPRIT (*Estimation of Signal Parameters by Rotational Invariance Techniques*) [1986-1990]:
    - ★ Tiene una exactitud un poco mayor que los demás.
    - ★ La ventaja principal es que no hay frecuencias espurias porque no aparecen los ceros del ruido.

## 3 Apéndice: El problema de estimación de direcciones de arribo

## Apéndice: el problema de estimación de posición de fuentes radiantes

# El problema de estimación de posición de fuentes radiantes



$$\mathbf{y}(n) = \begin{bmatrix} 1 & 1 & \dots & 1 \\ e^{i\omega_c \tau_1} & e^{i\omega_c \tau_2} & \vdots & e^{i\omega_c \tau_N} \\ \vdots & \vdots & \vdots & \vdots \\ e^{i\omega_c (M-1)\tau_1} & e^{i\omega_c (M-1)\tau_2} & \vdots & e^{i\omega_c (M-1)\tau_N} \end{bmatrix} \begin{bmatrix} s_1(n) \\ \vdots \\ s_N(n) \end{bmatrix} + \mathbf{v}(n)$$


## Planteo del problema

- Disponemos de un conjunto de sensores que reciben señales de fuentes remotas.
- Queremos determinar la dirección desde donde arriban las señales.

# Acerca de las fuentes

Para modelar las fuentes tomaremos las siguientes hipótesis:

- 1 Contamos con un número conocido de fuentes ( $N$ ).
- 2 Cada una de las fuentes transmite un señal  $s_j(t)$  ( $j = 1, \dots, N$ ).
- 3 El medio de transmisión es no dispersivo.
- 4 Las fuentes están muy alejadas y se comportan como emisores puntuales (sin volumen). Esto permite hacer una aproximación de onda plana:




- 5 Además cada una de las señales  $s_j(t)$  de las fuentes las vamos a muestrear en los sensores, obteniendo señales discretas  $s_j(n)$ , que agruparemos en un vector  $\mathbf{x}$ :

$$\mathbf{e}(n) = \begin{bmatrix} s_1(n) & \dots & s_N(n) \end{bmatrix}^T.$$

Con estas hipótesis la posición de las fuentes queda únicamente determinado por el ángulo con el que arriban al array las señales de cada fuente

# Acerca de los sensores (1)

Consideraremos que tenemos  $M$  sensores equiespaciados una distancia  $d$ . Cuando una fuente emite una señal, ésta no llega al mismo tiempo a todos los sensores:



El tiempo adicional de viaje de la señal entre sensor y sensor es:

$$\frac{d \sin(\phi_j)}{c}$$

donde  $\phi_j$  es el ángulo de arribo de la señal  $s_j(n)$  y  $c$  es la velocidad de propagación.

## Acerca de los sensores (2)

Por lo tanto, referido al sensor 1, el sensor k-ésimo demora:

$$(k-1) \frac{d \sin(\phi_j)}{c}$$

segundos en recibir la señal enviada por la fuente j-ésima.

Si para cada señal  $s_i(n)$  definimos:

$$\tau_j = \frac{d \sin(\phi_j)}{c}$$

y asumimos que los sensores son idénticos, lineales y se comportan del mismo modo para cualquier dirección de arribo podemos escribir a la señal recibida por el array entero como:

$$\mathbf{y}(n) = \begin{bmatrix} 1 & 1 & \dots & 1 \\ e^{i\omega_c \tau_1} & e^{i\omega_c \tau_2} & \vdots & e^{i\omega_c \tau_N} \\ \vdots & \vdots & \vdots & \vdots \\ e^{i\omega_c (M-1)\tau_1} & e^{i\omega_c (M-1)\tau_2} & \vdots & e^{i\omega_c (M-1)\tau_N} \end{bmatrix} \begin{bmatrix} s_1(n) \\ \vdots \\ s_N(n) \end{bmatrix}$$

# La equivalencia entre ambos modelos

- El modelo de arrays de sensores es muy similar al de frecuencias de sinusoides:

$$\mathbf{y}(n) = \begin{bmatrix} 1 & 1 & \dots & 1 \\ e^{i\omega_c \tau_1} & e^{i\omega_c \tau_2} & \vdots & e^{i\omega_c \tau_N} \\ \vdots & \vdots & \vdots & \vdots \\ e^{i\omega_c (M-1)\tau_1} & e^{i\omega_c (M-1)\tau_2} & \vdots & e^{i\omega_c (M-1)\tau_N} \end{bmatrix} \begin{bmatrix} s_1(n) \\ \vdots \\ s_N(n) \end{bmatrix}$$

- En el vector  $\mathbf{e}(n)$  teníamos sinusoidales y ahora tenemos señales arbitrarias.
- De todas formas no nos interesa la forma exacta de las señales  $s_j(n)$ . Sólo nos interesa lo siguiente:
  - Que las señales continuas  $s_j(t)$  estén muestreadas de acuerdo al teorema de Shannon.
  - Que las señales estén descorrelacionadas entre sí.
  - Que los sensores estén lo suficientemente juntos entre si como para que cuando los sensores tomen las muestras de las señales que llegan, la dirección de arribo esté unívocamente definida.
  - Con estas consideraciones, el método Music puede aplicarse a la estimación de direcciones de arribo.